


Rapport

Calcul Statistique et incertitudes



INP - ENSIACET

Date : 05/2026

GROUPE 4

David TOFAN

Esteban CLEMENTE

1. INTRODUCTION

Investir en bourse revient à prendre une décision dans l'incertitude : à chaque instant, le cours futur d'une action est une variable aléatoire dont la distribution est inconnue. L'approche d'observer le cours actuel et décider sans quantifier l'incertitude est équivalente à un calcul d'ingénierie sans barres d'erreur.

L'objectif de ce travail est de construire un modèle statistique complet qui, à partir de l'historique du cours Air Liquide (Al.PA), produit une distribution de probabilité du cours futur assortie d'intervalles de confiance quantifiés.

La règle de décision finale est probabiliste : à 60% de confiance, peut-on estimer que le cours va monter après investissement ?

Le code R fournit affiche les résultats dans la console en plus.

1.1 Initialisation

```
Code R
31 RATIO_TRAIN    <- 0.75
32 PERIODE        <- 5
33 N_SIMULATIONS  <- 2000
34 NIVEAU_INVEST  <- 0.6
```

Variable `PERIODE` :

La fréquence indique combien d'observations constituent une période complète. La bourse ouvre 5 jours par semaine (de lundi à vendredi). On dit à R que la saisonnalité de base est hebdomadaire.

Variable `NIVEAU_INVEST` :

Elle correspond au seuil de confiance à partir duquel on décide d'agir.

En la modifiant, on agit sur notre prise de décision (prise de risques ou non).

Profil	NIVEAU_INVEST	Comportement
Spéculatif	0.55	Agit souvent, risque élevé
Équilibré	0.60 – 0.70	Bon compromis signal/risque
Conservateur	0.80	N'agit que sur signaux forts
Très prudent	0.90+	Quasi-inaction

La série est découpée en 75% train / 25% test pour valider les prédictions sur des données non vues.

La série Air Liquide (AI.PA) compte **488 observations** journalières (juin 2024 – mai 2026), découpées en **366 observations d'entraînement** (75%) et **122 observations de test** (25%).

Cours Air Liquide (AI.PA) — Historique complet




Figure 1 - train / test du cours de l'action

2. Décomposition de la série et test de normalité

2.1 Le modèle additif de Holt-Winters

$$Y_t = T_t + S_t + R_t$$

Le cours Y_t est modélisé comme la somme de trois variables aléatoires :

On simule avec Monte-Carlo chacune de ces variables.

V.A.	Symbole	Signification physique	Distribution supposée
Tendance	T_t	Direction de long terme du cours	$\mathcal{N}(\mu_T, \sigma_T^2)$
Saisonnalité	S_t	Motif répétitif sur 5 jours	$\mathcal{N}(\mu_S, \sigma_S^2)$
Résidu	R_t	Chocs imprévisibles du marché	$\mathcal{N}(0, \sigma_R^2)$

La **tendance** T_t est calculée par une moyenne mobile centrée d'ordre $m = 5$:

$$T_t = \frac{1}{m} \sum_{k=-\lfloor m/2 \rfloor}^{\lfloor m/2 \rfloor} Y_{t+k} = \frac{1}{5} \sum_{k=-2}^2 Y_{t+k}$$

Ce qui donne concrètement :

$$T_t = \frac{Y_{t-2} + Y_{t-1} + Y_t + Y_{t+1} + Y_{t+2}}{5}$$

C'est pourquoi `na.omit` est nécessaire : les 2 premiers et 2 derniers points n'ont pas assez de voisins pour calculer la moyenne mobile — ils valent NA. La tendance capture la direction générale du cours sur plusieurs semaines.




Figure 2

La distribution de la tendance est étalée sur [155 ; 185 €] et légèrement asymétrique, ce qui explique le rejet de la normalité ($p = 2 \times 10^{-4}$). La courbe observée reste néanmoins proche de la gaussienne théorique, et le boxplot confirme l'absence de valeurs aberrantes. L'approximation normale est donc retenue comme raisonnable.

La **saisonnalité** S_t est l'effet du jour de la semaine. Elle est calculée en soustrayant la tendance au cours puis en moyennant par position dans la période :

$$S_t = (Y_t - T_t)_{\text{même jour de semaine}}$$

Par construction, la somme des 5 valeurs saisonnières sur une semaine est nulle :

$$\sum_{j=1}^5 S_j = 0$$




Figure 3

La distribution de la saisonnalité est bimodale, avec deux pics bien distincts très éloignés de la gaussienne théorique. `decompose()` ne génère que 5 valeurs distinctes répétées, produisant une distribution discrète par construction. Le boxplot confirme une dispersion quasi nulle ($\sigma_S^2 = 0,005$) centrée sur 0 — la saisonnalité hebdomadaire est négligeable sur ce cours.

Le **résidu** R_t est ce qui reste après avoir retiré tendance et saisonnalité :

$$R_t = Y_t - T_t - S_t$$

C'est le bruit du marché — la partie imprévisible du cours. Si le modèle est valide, ce résidu doit être du bruit blanc gaussien centré en zéro : $R_t \sim \mathcal{N}(0, \sigma_R^2)$.




Figure 4

La distribution du résidu est la plus proche d'une gaussienne centrée en 0. Le boxplot révèle quelques valeurs aberrantes isolées correspondant à des chocs de marché ponctuels, mais la distribution reste globalement symétrique. Ce résultat confirme que le modèle capture correctement le signal du cours.

2.2 Holt-Winters et ses paramètres α, β, γ

```
Code R
78 modele_hw <- hw(train, seasonal = "additive", h =
length(test))
```

Phase 1 - Optimisation sur le train (366 jours)

Le modèle de Holt-Winters lisse exponentiellement chacune des trois composantes via trois équations récursives. Contrairement à `decompose()` qui calcule une décomposition statique, `hw()` met à jour les composantes en temps réel au fur et à mesure que de nouvelles observations arrivent :

$$\ell_t = \alpha(Y_t - S_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})(\text{niveau})$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}(\text{tendance})$$

$$S_t = \gamma(Y_t - \ell_t) + (1 - \gamma)S_{t-m}(\text{saisonnalité})$$

Les trois paramètres sont estimés automatiquement par maximum de vraisemblance, c'est-à-dire que R cherche les valeurs de α, β, γ qui maximisent la probabilité d'avoir observé les données du train :

$$(\hat{\alpha}, \hat{\beta}, \hat{\gamma}) = \arg \max_{\alpha, \beta, \gamma} \sum_{t=1}^n \log f(Y_t | \alpha, \beta, \gamma)$$

Pour une loi gaussienne, maximiser la log-vraisemblance revient à **minimiser la somme des erreurs au carré** (MSE). Leur interprétation est la suivante :

R fait tourner la boucle récursive et cherche les α, β, γ qui minimisent les erreurs. À la fin il retient :

- $\alpha = 0.87$ (Le modèle est **très réactif** aux variations journalières du cours)
- $\beta = 0.018$
- $\gamma = 0.0001$

L'état final : $\ell_{366}, b_{366}, S_{366}, S_{365}, \dots, S_{362}$

Phase 2 - Prédiction sur le test (h = 1 à 122)

Avec les paramètres figés, le modèle applique pour chaque h :

$$\hat{Y}_{366+h} = \ell_{366} + h \cdot b_{366} + S_{366+h-5}$$

Seul $S_{366+h-5}$ varie — il recycle les 5 valeurs saisonnières de la dernière semaine du train

Phase 3 - Stockage

C'est d'ailleurs pour ça que le modèle se dégrade avec le temps : $h \cdot b_{366}$ extrapole une pente **linéaire fixe**, alors que le vrai cours peut changer de direction à tout moment.




Figure 7 (Annexe)

2.3 Pourquoi tester la normalité ?

Notre modèle Monte Carlo suppose que T_t , S_t et R_t suivent des **lois normales**. Si ce n'est pas le cas, les intervalles de confiance calculés seront faux — et la règle de décision sera non fiable.

On utilise le test de validité suivant :

Le test de Shapiro-Wilk est le test le plus puissant pour les petits échantillons. Il construit une statistique W qui mesure à quel point les quantiles empiriques s'alignent avec ceux d'une loi normale théorique. La **p-value** est la probabilité d'obtenir un échantillon aussi "non-normal" si la vraie distribution était normale :

```
Code R
93 tes <- shapiro.test(x)

# Si p-value > 0.05 → on ne peut pas rejeter H0 : x ~ N(mu,
sigma^2)

# Si p-value < 0.05 → normalité REJETÉE à 95%
```

Le test de Shapiro-Wilk rejette la normalité pour les trois composantes :

Composante	p-value	Décision
Tendance T_t	2×10^{-4}	Rejetée à 95%
Saisonnalité S_t	≈ 0	Rejetée à 95%
Résidu R_t	≈ 0	Rejetée à 95%

Ce résultat doit être nuancé. Avec $n = 366$ observations, Shapiro-Wilk est très puissant et détecte des déviations **statistiquement significatives mais pratiquement négligeables**.

Pour S_t , le rejet s'explique par la nature discrète de la saisonnalité : `decompose()` ne produit que 5 valeurs distinctes répétées, générant une distribution multimodale — visible sur la PDF avec ses deux pics.

Les graphiques PDF montrent néanmoins que T_t et R_t restent proches d'une gaussienne. L'hypothèse normale est donc retenue comme **approximation raisonnable** dans le cadre de ce modèle.

3. Construction des 6 fonctions statistiques

3.1 La matrice de variance-covariance Σ

```
Code R
134 composantes <- cbind(tendance[1:n_min], saison[1:n_min],
residu[1:n_min])
137 mu_vecteur <- colMeans(composantes)
138 Sigma <- cov(composantes)
```

Les trois composantes (T, S, R) **ne sont pas indépendantes**. La matrice Σ capture toutes ces dépendances :

$$\Sigma = \begin{pmatrix} \text{Var}(T) & \text{Cov}(T, S) & \text{Cov}(T, R) \\ \text{Cov}(S, T) & \text{Var}(S) & \text{Cov}(S, R) \\ \text{Cov}(R, T) & \text{Cov}(R, S) & \text{Var}(R) \end{pmatrix}$$

Chaque terme est estimé empiriquement sur l'historique. La **covariance** entre deux variables X et Z mesure leur tendance à varier ensemble :

$$\text{Cov}(X, Z) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(z_i - \bar{z})$$

Si $\text{Cov}(T, R) > 0$: quand la tendance monte, les résidus ont tendance à être positifs aussi (marché optimiste).

Si $\text{Cov}(T, R) < 0$: effet inverse (mean-reversion).

On modélise alors (T, S, R) comme un **vecteur gaussien corrélé** :

$$\begin{pmatrix} T \\ S \\ R \end{pmatrix} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

Ignorer les corrélations (prendre $\boldsymbol{\Sigma}$ diagonale) **sous-estimerait ou sur-estimerait** la variance totale du cours — et donc la largeur des intervalles de confiance.

On obtient le vecteur $\boldsymbol{\mu}$:

Composante	Valeur moyenne
T (Tendance)	170.85 €
S (Saisonnalité)	0.0004
R (Résidu)	-0.0041

La matrice $\boldsymbol{\Sigma}$ estimée confirme que la tendance domine largement avec $\sigma_T^2 = 56,38$, contre $\sigma_S^2 = 0,005$ et $\sigma_R^2 = 1,26$. La corrélation $\sigma_{TR} = 0,61$ est faible mais non nulle, justifiant l'utilisation du vecteur gaussien corrélé.

3.2 Les 6 fonctions

Le cours définit les préfixes pour toute distribution en R :

- $d \rightarrow$ **densité** : valeur de la courbe en cloche en un point
- $p \rightarrow$ **probabilité cumulée** : probabilité d'être en dessous d'un seuil
- $q \rightarrow$ **quantile** : valeur correspondant à une probabilité

- $r \rightarrow$ **simulation** : tirage aléatoire depuis la distribution
- $e \rightarrow$ **espérance** (moyenne)
- $v \rightarrow$ **variance**

rY(n) — Simulation Monte Carlo

```
Code R
144 rY <- function(n = N_SIMULATIONS) {
  sims <- rmvnorm(n, mean = mu_vecteur, sigma = Sigma)
  rowSums(sims) # Y = T + S + R
}
```

`rmvnorm` tire $n = 2000$ réalisations du vecteur gaussien corrélé (T, S, R) . Pour chaque tirage k :

$$\hat{Y}^{(k)} = T^{(k)} + S^{(k)} + R^{(k)}, k = 1, \dots, 2000$$

On obtient 2000 cours possibles demain — ce sont des **simulations équiprobables** du futur selon notre modèle. La loi des grands nombres garantit que leur distribution converge vers la vraie distribution de $\hat{Y}$ quand $n \rightarrow \infty$.

pY(y) — Probabilité de gain ou de perte

```
Code R
149 pY <- function(y, n = N_SIMULATIONS) ecdf(rY(n))(y)
```

`ecdf` est la **fonction de répartition empirique** (p.26 du cours) :

$$\hat{F}_n(y) = \frac{1}{n} \sum_{k=1}^n \mathbf{1}[\hat{Y}^{(k)} \leq y]$$

En pratique : $pY(183)$ compte combien de simulations donnent un cours ≤ 183 € et divise par 2000. Si le résultat est 0.30, cela signifie que **30% des scénarios prévoient un cours en dessous de 183 €, donc 70% prévoient un cours au-dessus** — signal d'achat.

qY(p) — Seuils de décision

```
Code R
150 qY <- function(p, n = N_SIMULATIONS) quantile(rY(n), probs = p)
```

C'est l'**inverse de pY**. $qY(0.40)$ répond à la question : *"En dessous de quelle valeur se trouvent 40% des cours simulés ?"*. Ce sont ces quantiles qui définissent les bornes de la décision d'investissement.

eY() et vY() — Espérance et variance

```
Code R
151 eY <- function(n = N_SIMULATIONS) mean(rY(n))
152 vY <- function(n = N_SIMULATIONS) var(rY(n))
```

L'**espérance** est le cours moyen prédit — la meilleure estimation ponctuelle de $\hat{Y}$ (p.48 du cours — estimateur non biaisé) :

$$\mathbb{E}[\hat{Y}] \approx \frac{1}{n} \sum_{k=1}^n \hat{Y}^{(k)}$$

La **variance** mesure la dispersion autour de cette moyenne — plus elle est grande, plus le cours futur est incertain et plus les intervalles de confiance seront larges (p.53) :

$$\text{Var}[\hat{Y}] \approx \frac{1}{n-1} \sum_{k=1}^n (\hat{Y}^{(k)} - \mathbb{E}[\hat{Y}])^2$$

4. Propagation Monte Carlo et Intervalle de Confiance à 95%

La propagation des distributions consiste à transmettre l'incertitude des variables d'entrée T , S et R jusqu'à la variable de sortie $\hat{Y}$. Les 2 000 réalisations produites par $rY()$ constituent l'échantillon sur lequel repose l'ensemble des calculs d'incertitude.

Intervalle de confiance à 95%

L'intervalle de confiance à 95% est calculé à partir des quantiles empiriques de la distribution simulée :

$$IC_{95\%} = [Q_{0.025}(\hat{Y}) ; Q_{0.975}(\hat{Y})]$$

Les bornes sont estimées directement sur l'échantillon Monte Carlo :

$$Q_{0.025} = \text{quantile}(\text{cours_simules}, 0.025), Q_{0.975} = \text{quantile}(\text{cours_simules}, 0.975)$$

Les 2 000 simulations produisent :

$$\mathbb{E}[\hat{Y}] = 170,92 \text{ €}, \text{Var}[\hat{Y}] = 59,29$$

$$IC_{95\%} = [155,83 ; 186,18] \text{ €}$$

$$IC_{95\%}(E[\hat{Y}]) = [170,58 ; 171,25] \text{ €}$$

L'IC sur la moyenne est très étroit ($\sim 0,67$ €) grâce aux 2 000 tirages, confirmant la stabilité numérique. L'IC sur le cours individuel est en revanche large (~ 30 €), reflet de l'incertitude irréductible du marché.

5. Règle de décision d'investissement

5.1 Analogie avec le test statistique

La règle de décision est formellement **identique à un test statistique bilatéral**. Dans un test classique, on compare u_{exp} à l'IC de la distribution sous H_0 . Ici, on compare le cours actuel Y_{actuel} aux quantiles de la distribution prédite :

Test statistique	Notre modèle
H_0 : le cours est normal	Le cours actuel est dans la zone prédite
u_{exp}	Y_{actuel}
IC sous H_0	$[Q_{40\%} ; Q_{60\%}]$
u_{exp} dans IC $\rightarrow$ ne pas rejeter H_0	Cours dans zone $\rightarrow$ ATTENDRE
u_{exp} hors IC bas $\rightarrow$ rejeter H_0	Cours sous zone $\rightarrow$ ACHETER

5.2 Calcul de la probabilité de gain

```
Code R
192 proba_gain <- 1 - pY(cours_actuel)
193 proba_perte <- pY(cours_actuel)
```

$pY(\text{cours_actuel})$ calcule $P(\hat{Y} \leq Y_{\text{actuel}})$ — la fraction des simulations qui prédisent un cours **inférieur ou égal** au cours actuel. Donc :

$$P(\text{gain}) = P(\hat{Y} > Y_{\text{actuel}}) = 1 - \hat{F}_n(Y_{\text{actuel}})$$

5.3 Les trois zones de décision

```
Code R
194 q_bas <- qY(1 - NIVEAU_INVEST) # = qY(0.40)
195 q_haut <- qY(NIVEAU_INVEST) # = qY(0.60)
```

Avec $NIVEAU_INVEST = 0.60$, la zone neutre $[q_{bas} ; q_{haut}]$ contient **20%** des simulations — les 20% centraux de la distribution. Les zones d'action (ACHETER ou VENDRE) représentent chacune **40%** des simulations :

$$\underbrace{P(\hat{Y} \leq q_{bas})}_{40\%} + \underbrace{P(q_{bas} < \hat{Y} \leq q_{haut})}_{20\%} + \underbrace{P(\hat{Y} > q_{haut})}_{40\%} = 100\%$$

Le cours actuel de **183,28 €** est supérieur au quantile $Q_{60\%} = 173,14 €$:

$$Y_{actuel} = 183,28 € > Q_{60\%} = 173,14 €$$

$$P(\text{gain}) = 5\% P(\text{perte}) = 95,2\%$$

Décision : VENDRE, le cours actuel est anormalement élevé par rapport à la distribution prédite. Seulement 5% des 2 000 scénarios simulés prévoient un cours supérieur à 183,28 €, ce qui constitue un signal de vente fort au seuil de confiance retenu de 60%.

Distribution du cours prédit $\hat{Y}$ (Monte Carlo, N=2000)




Figure 4

Conclusion

On a pu prédire le cours d'Air Liquide (AI.PA) sur le marché, en décomposant 488 observations journalières selon Holt-Winters puis en propageant l'incertitude par simulation Monte Carlo ($N = 2\,000$).

Le cours moyen prédit s'établit à $\mathbb{E}[\hat{Y}] = 170,92 \text{ €}$ avec un IC 95% de $[155,83 ; 186,18 \text{ €}]$. L'analyse de sensibilité révèle que la tendance T_t est la variable dominante avec **97,9%** de la variance totale, tandis que la saisonnalité hebdomadaire s'avère négligeable.

La règle de décision conclut à un signal de **VENDRE** : le cours actuel de 183,28 € dépasse le quantile $Q_{60\%} = 173,14 \text{ €}$, avec une probabilité de perte de **95,2%**.

NOTE : le modèle est calibré sur l'historique passé (366 observations d'entraînement couvrant juin 2024 – fin 2025). Les paramètres μ et Σ sont des estimations figées à cet instant. Or les marchés financiers sont non-stationnaires : la tendance peut s'inverser brutalement suite à une crise, une décision de la BCE ou des résultats d'entreprise inattendus. Plus on s'éloigne de la date d'entraînement, plus le contexte économique peut diverger des conditions passées, rendant les paramètres estimés obsolètes.

Références

[1] Hyndman, R.J. & Athanasopoulos, G. (2021), *Forecasting: Principles and Practice*, 3rd ed., Section 8.3 — <https://otexts.com/fpp3/holt-winters.html>

[2] Bourgeois, F. (2026) *Calcul Statistique et incertitudes — Enseignement à l'usage des ingénieurs*. INP-ENSIACET, Toulouse.